Classificador K-NN sobre o Dataset Iris
Visão Computacional

Davi Garcia Lazzarin[1], **Mardoqueu Freire Nunes**[1]
GRR20204398 – GRR20211773

[1]Departamento de Informática – Universidade Federal do Paraná (UFPR)
Curitiba – PR – Brazil

dgl20@inf.ufpr.br, mfn21@inf.ufpr.br

Abstract. *Este trabalho implementa um classificador K-NN para o dataset Iris usando OpenCV (`cv2.ml.KNearest`), com análise exploratória, PCA e escolha do hiperparâmetro k por validação cruzada. O programa (`iris_knn.py`) gera estatísticas descritivas e seis gráficos em `saida_iris/`. Com divisão 80% treino / 20% teste e $k = 3$ escolhido por 5-fold, o modelo atinge 93,3% de acurácia no teste.*

1. Introdução

O dataset Iris tem 150 flores em 3 classes balanceadas (*setosa*, *versicolor*, *virginica*), cada uma descrita por 4 medidas: comprimento e largura da sépala e da pétala. É um problema clássico porque uma classe é facilmente separável e as outras duas se misturam parcialmente, o que permite avaliar bem um classificador.

O K-NN foi escolhido por ser simples. Para classificar uma flor nova, ele mede a distância até todos os exemplos guardados e faz uma votação entre os k vizinhos mais próximos. O trabalho mostra esse pipeline completo, da exploração dos dados até a avaliação final.

2. Metodologia

O script `iris_knn.py` executa as etapas abaixo, sempre com semente fixa (`SEED=42`) para reprodutibilidade.

Dados e padronização. Os dados vêm de `iris.data` (data set passado pelo professor). Antes do PCA e do K-NN as variáveis são padronizadas (média zero, desvio um), pois a sépala é medida em escala maior que a pétala e dominaria a distância Euclidiana sem esse ajuste. O escalonador é ajustado só no treino e aplicado no teste, para não vazar informação.

Análise exploratória. São calculados média, desvio-padrão e moda no geral e por classe, além da correlação comprimento $\times$ largura da sépala e da pétala por classe.

PCA com OpenCV. A redução de dimensionalidade usa `cv2.PCACompute2` sobre os dados padronizados, projetando as 4 medidas em 2 eixos principais para visualização.

Divisão treino/teste. Divisão estratificada 80/20 (120 treino, 30 teste, 10 de cada classe no teste), preservando a proporção das classes.

K-NN e escolha de k. O classificador é `cv2.ml.KNearest` com distância Euclidiana. O valor de k é testado em {1, 3, 5, 7, 9, 11, 13, 15} com validação cruzada 5-fold **apenas no treino**; o teste fica guardado para a avaliação final. Um experimento extra repete o K-NN usando só os 2 componentes do PCA e desenha as fronteiras de decisão nesse plano.

3. Resultados

Panorama numérico. As três classes têm 50 amostras cada. A *setosa* é pequena na pétala (média de 1,46 cm de comprimento) e a *virginica* é a maior (5,55 cm), com a *versicolor* no meio (4,26 cm). O PCA concentra 73,0% da variância no PC1 e 22,9% no PC2 (95,8% somados), ou seja, quase toda a informação cabe em 2 eixos. O melhor k foi 3, com 96,7% de acurácia média na validação cruzada. No teste final, a acurácia foi de 93,3% (28 de 30 acertos): todos os erros foram 2 *virginica* classificadas como *versicolor*. Com só 2 componentes do PCA a acurácia se manteve em 93,3%.

3.1. O que mostra cada gráfico de `saida_iris/`

Figura 1 – Dispersão com tendência. Cada ponto é uma flor, colorido por espécie, com o coeficiente de correlação r na legenda e uma reta de tendência por classe. Na pétala (direita), a *setosa* (azul) forma um grupo isolado no canto inferior esquerdo, pétala pequena e estreita. Já *versicolor* e *virginica* ficam lado a lado e se tocam no centro, mostrando que a confusão do classificador virá dali. Na sépala (esquerda) os três grupos se sobrepõem bem mais, ou seja, a sépala sozinha separa mal.

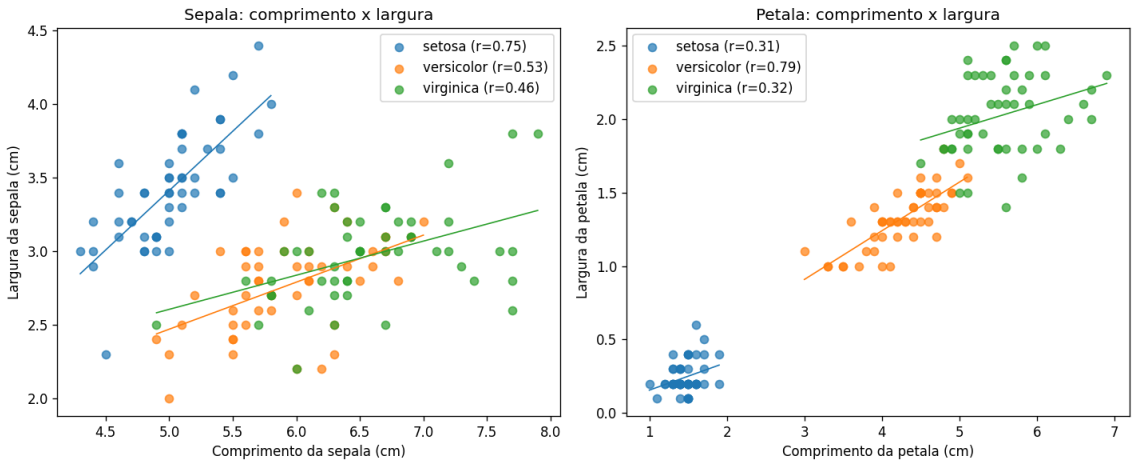


Figura 1. Relação comprimento × largura da sépala (esq.) e da pétala (dir.), por classe.

Figura 2 – Histogramas por variável. São 4 painéis, um por medida, com as três classes sobrepostas. Nas duas medidas da pétala (linha de baixo), a barra azul da *setosa* está totalmente à esquerda e isolada, por isso ela é sempre acertada. As barras laranja (*versicolor*) e verde (*virginica*) se sobrepõem na região central, confirmando que o erro se concentra entre essas duas. Nas medidas da sépala (linha de cima) a sobreposição é ainda maior.

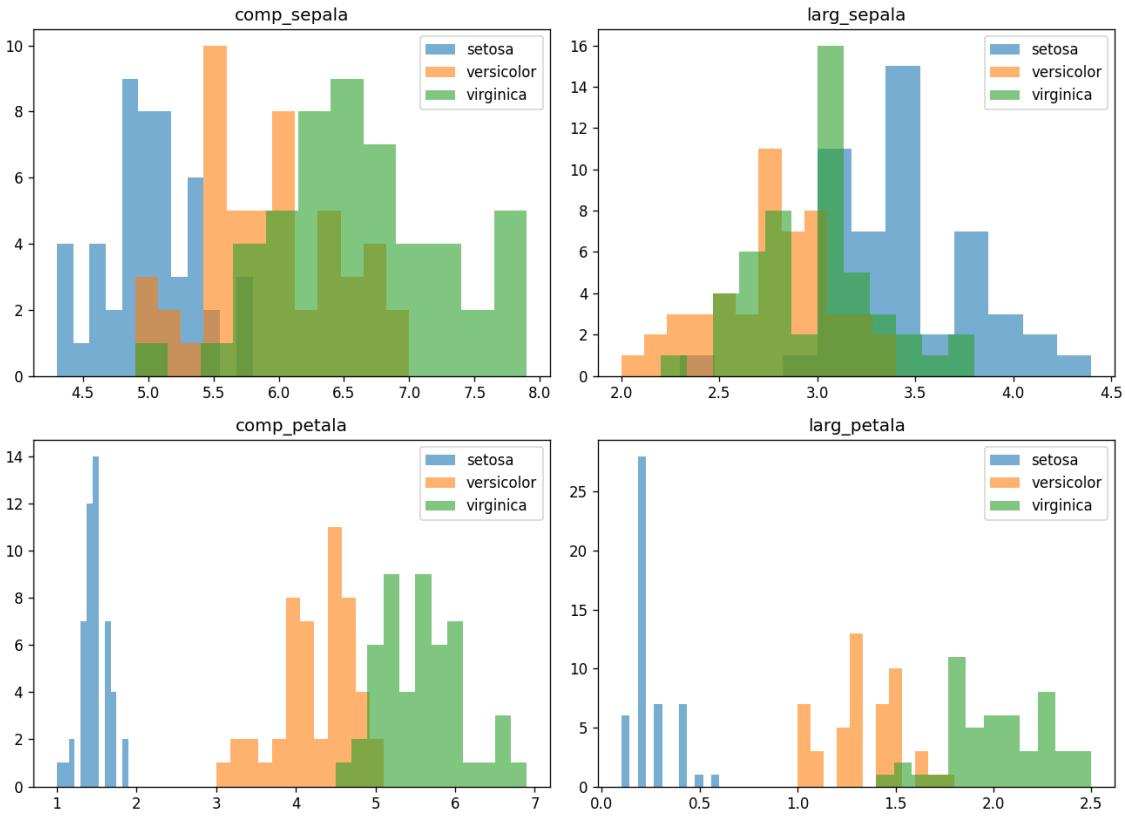


Figura 2. Histogramas das 4 medidas, uma cor por classe.

Figura 3 – PCA em 2D. Cada ponto é uma flor projetada nos dois eixos que mais concentram variação (PC1 com 73,0%, PC2 com 22,9%). A *setosa* aparece isolada à esquerda; *versicolor* e *virginica* formam duas nuvens vizinhas à direita com pequena sobreposição na fronteira. Como os dois eixos guardam 95,8% da informação, essa figura resume bem a dificuldade real do problema.

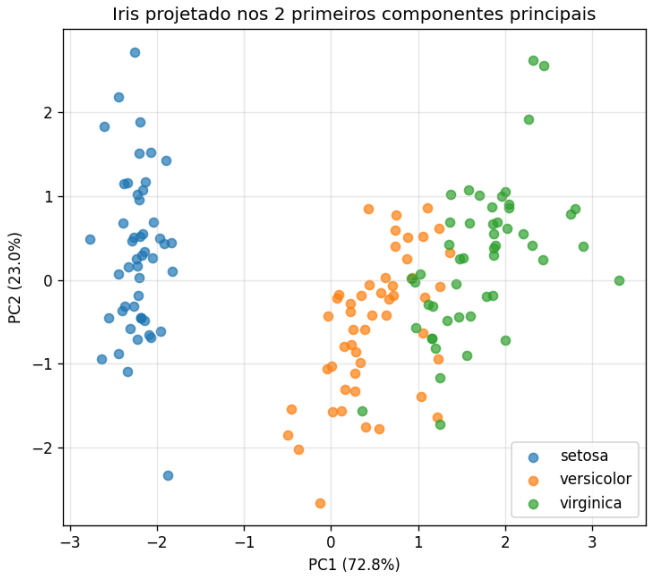


Figura 3. Projeção das 150 flores nos 2 primeiros componentes principais.

Figura 4 – Escolha de k. O eixo x é o k testado, o eixo y é a acurácia média nos 5 folds, e a barra vertical é a variação entre folds. Valores muito pequenos de k oscilam mais e valores grandes suavizam demais a fronteira. O pico está em $k = 3$ (linha tracejada, 96,7%), por isso ele foi adotado para o teste final.

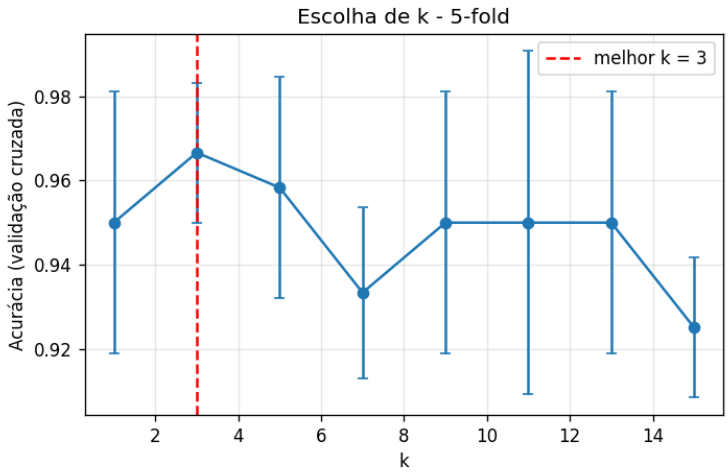


Figura 4. Acurácia média da validação cruzada 5-fold em função de k. Barras verticais indicam o desvio entre folds.

Figura 5 – Fronteiras de decisão. O fundo pintado em três cores mostra o que o K-NN responderia para qualquer ponto do plano PCA: região azul = *setosa*, laranja = *versicolor*, verde = *virginica*. Os círculos pequenos são o treino e as estrelas grandes são o teste. Estrelas dentro da região de sua própria cor são acertos; as que caem na região vizinha (na fronteira laranja/verde) são os 2 erros *virginica* $\rightarrow$ *versicolor*. A região azul é ampla e sem estrelas erradas, confirmando que a *setosa* é trivial para o modelo.

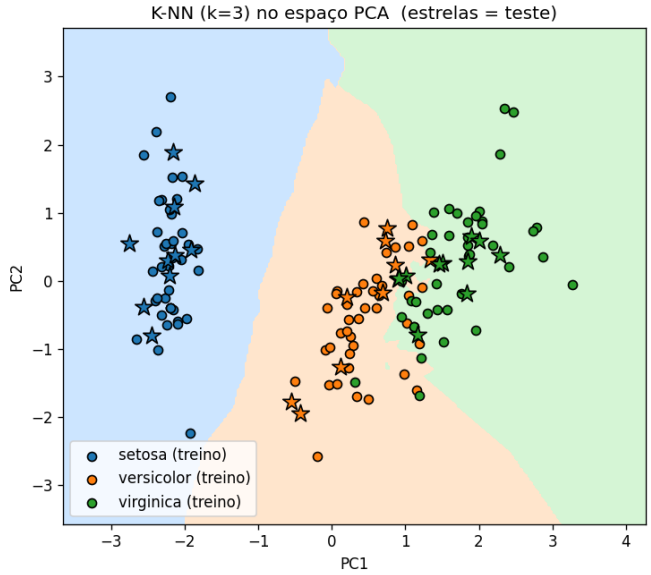


Figura 5. Fronteiras de decisão do K-NN ($k = 3$) no plano PCA. Fundo colorido = classe prevista; círculos = treino; estrelas = teste.

4. Conclusão

O K-NN com $k = 3$ resolve bem o Iris: 93,3% no teste usando as 4 variáveis, e o mesmo desempenho usando só 2 componentes do PCA, o que mostra que o problema é essencialmente bidimensional. A limitação está na fronteira *versicolor* $\times$ *virginica*, onde 2 amostras de teste se confundem.

5. Repositório

Repositório com o link para o GitHub: https://github.com/MardoNunes/visao-computacional/tree/TA04.

6. Referência

Base Iris (UCI): https://archive.ics.uci.edu/dataset/53/iris.
Documentação do K-NN do OpenCV (`cv2.ml.KNearest`): https://docs.opencv.org/4.x/dd/de1/classcv_1_1ml_1_1KNearest.html.
Classificador KNN: https://ufprvirtual.ufpr.br/pluginfile.php/2926231/mod_resource/content/3/13-compVis-classification-kNN-train-val-test-k-fold.pdf
Recognição e DataSets: https://ufprvirtual.ufpr.br/pluginfile.php/2926230/mod_resource/content/6/12-compVis-recognition-datasets.pdf